

HM-RAG: 层级式多智能体多模态检索增强生成

Pei Liu^{1,2}, Xin Liu², Ruoyu Yao², Junming Liu¹, Siyuan Meng¹, Ding Wang^{1*}, Jun Ma^{23*}

¹Shanghai Artificial Intelligence Laboratory ²The Hong Kong University of Science and Technology (Guangzhou)

³The Hong Kong University of Science and Technology

pliu061@connect.hkust-gz.edu.cn wangding@pjlab.org.cn jun.ma@ust.hk

摘要


尽管检索增强生成 (RAG) 能够借助外部知识增强大语言模型 (LLM), 但传统的单智能体 RAG 在解决需要跨异构数据生态系统进行协同推理的复杂查询时, 仍存在根本性局限。本文提出 HM-RAG——一种新颖的分层多智能体多模态 RAG 框架, 它率先通过协作智能实现跨结构化、非结构化与图数据的动态知识合成。该框架采用三层架构, 包含专用智能体: 分解智能体, 通过语义感知的查询重写和模式引导的上下文增强, 将复杂查询拆解为上下文连贯的子任务; 多源检索智能体, 利用专为向量、图及基于网络的数据库设计的即插即用模块, 执行并行、模态特定的检索; 决策智能体, 通过一致性投票整合多源答案, 并借助专家模型精炼解决检索结果中的不一致性。该架构通过融合文本、图关系与网络来源的证据, 实现了对查询的全面理解, 在 ScienceQA 和 Crisis-MMD 基准测试上, 相比基线 RAG 系统, 答案准确率显著提升 12.95%, 问题分类准确率提升 3.56%。值得注意的是, HM-RAG 在两个数据集的零样本设置下均取得了最先进的结果。其模块化架构在确保严格数据治理的同时, 支持无缝集成新的数据模态, 标志着在解决 RAG 系统中多模态推理与知识合成的关键挑战方面迈出了重要一步。代码已开源: <https://github.com/ocean-luna/HMRAG>。

关键词


检索增强生成 (RAG)、多模态表示、多智能体系统、多源检索增强生成

1 引言

在这个数据快速激增的时代, 从异构源中高效检索相关信息的能力已成为现代信息系统的基石^[14]。多模态检索系统集成文本、图像、向量化数据和网页内容, 在电子商务、医疗健康和科学研究等领域变得不可或缺^[59]。这些系统能够无缝导航不同类型的数据, 使用户能够跨多种模态获得可操作的见解。然而, 尽管近年来取得了显著进展, 多模态检索仍然面临重大挑战。复杂性源于需要协调查询类型的多样性、数据格式的异构性以及图 1:(a)单智能体单模态 RAG



(a) 单智能体单模态 RAG



(b) 多智能体多模态 RAG

与(b)多智能体多模态 RAG 的比较。多智能体多模态 RAG 通过将多模态数据转换为向量和图数据库来处理这些数据。它利用跨向量、图和网页数据库的多源检索, 实现更全面高效的信息检索。这种先进方法使多智能体多模态 RAG 在处理复杂查询和多样化数据类型方面具有优越性能, 使其区别于功能有限的单智能体单模态 RAG。

检索任务的各种目标, 所有这些目标都需要复杂的解决方案来弥合数据表示与用户意图之间的差距。

检索技术的发展历史上一直以单模态架构为中心, 其中查询和检索机制在单一预定义模态内运行[3, 33]。尽管基于文本的检索增强生成 (RAG) 系统在处理语言信息方面表现出色[43], 但其无法处理视觉内容的问题推动了基于图像的

RAG 方法的发展[7, 25, 41]。然而, 当前的多模态实现面临一个关键瓶颈: 尽管基于图像的 RAG 系统擅长视觉内容处理, 但它们往往无法在视觉元素与文本上下文之间建立连贯的跨模态关联。这一限制在多模态问答中尤为突出, 因为系统必须将视觉感知与文本语义相结合, 以生成上下文相关的回答。

近期, 基于图的检索框架被提出, 通过构建知识图谱来增强对文本相互依赖关系的建模, 典型代表包括 GraphRAG [12] 和 LightRAG [18]。这类方法进一步扩展来处理多模态输入 [37], 借助图结构精准捕获跨模态关系。尽管取得了这些进展, 基于图的方法面临固有取舍: 它们虽能有效捕获高层次模态交互, 却往往牺牲细粒度信息保真度。在需要精确检索文本片段的场景中, 这一问题尤为突出, 因为图建模所固有的抽象过程会模糊对精细分析至关重要的细粒度文本细节。

同时, 在协调不同模态的互补优势方面, 另一个关键挑战已被注意到 [13, 15, 31]。文本模态擅长编码细粒度的语义细节和概念关系, 而相比之下, 视觉模态则能够捕捉空间上下文并促进空间关系理解。当前的单模态系统 [33, 54] 在跨模态合成方面表现出关键局限性, 其产生的检索结果要么过度专精于文本精度, 要么局限于视觉模式识别。这种模态隔离在异构数据环境中造成了系统性脆弱性, 由于缺乏跨模态对齐协议, 检索操作过程中存在关键信息丢失的风险。例如, 在以文本为中心的系统中的视觉查询无法将概念性问题映射到示意性元素, 而在以视觉为导向的框架中, 文本密集型查询则缺乏词汇消歧机制。这些架构上的缺陷凸显出迫切需要能够协调细粒度语义细节与跨模态上下文连贯性的框架。

为应对这些挑战, 我们提出了层次化多智能体检索增强生成 (HM-RAG) 框架, 这是一种通过协调多智能体协作来增强多模态检索的新颖框架。HM-RAG 采用三层架构, 其专用智能体在 RAG 流水线中运行。分解智能体分析查询意图并动态重写请求以确保跨模态兼容性。多源检索智能体通过轻量级多模态检索在包括向量、图及网络数据库在内的多种数据源间进行并行知识获取。最后, 决策智能体利用领域特定验证策略综合并精炼候选回答, 以确保准确性和连贯性。这种层次化设计通过结构化的智能体交互, 系统地组织文本-图像证据整合, 实现分层推理。与传统方法不同, HM-RAG 结合了查询分解、并行化信息检索和专家引导的回答精炼, 以实现高效且上下文相关的响应。我们的贡献总结如下:

- 我们提出了一种新颖的模块化分层框架, 该框架将查询处理分解为基于代理的专用组件, 从而实现了可扩展且高效的多模态检索。
- 我们实现了多源即插即用检索集成, 支持跨不同数据源的无缝连接。通过将查询高效路由至基于向量、图和 Web 的检索智能体, 该方法确保了处理异构数据环境时的灵活性与效率, 从而简化了复杂的信息检索流程。
- 我们采用专家引导的精炼流程来提升响应质量, 以最少的专家监督确保运营效率与上下文精准度。
- 我们通过在基准数据集上的大量实验证明了 HM-RAG 的有效性, 并在 ScienceQA 和 CrisisMMD 基准上取得了最先进的性能。

2 相关工作

2.1 检索增强生成

RAG 系统在增强多模态推理能力方面取得了显著进展 [16, 20, 33, 47]。最初, 基于文本的 RAG 系统将大语言模型 (LLMs) 与外部文本知识相结合, 通过检索相关文本片段提升了问答任务的性能 [4, 27, 57]。然而, 随着视觉丰富文档日益普及, 纯文本系统的局限性逐渐显现, 从而推动了基于图像的 RAG 方法的发展 [5, 6, 38, 46]。尽管这些方法旨在为大型视觉语言模型 (VLMs) 检索视觉内容, 但在有效整合文本与图像模态方面仍面临挑战, 因为检索过程在很大程度上相互独立, 阻碍了对两者间关系的深入理解。

为了解决这些挑战, 基于图的 RAG 系统应运而生, 它利用结构化知识表示来捕获模态间和模态内的语义关系 [9, 18, 28, 44]。这些系统利用向量空间嵌入和拓扑关系对复杂的文档结构进行建模, 从而能够检索超越简单文本片段的语义连贯上下文 [12, 42, 53]。基于图的 RAG 系统在理解文本与图像之间的关系以及提取文本内部关系方面特别有效 [37]。然而, 当前的 RAG 实现通常依赖单一来源检索, 限制了其处理需要同时处理向量、图以及基于网络的数据库的复杂查询的能力 [19]。这一局限在需要私有数据检索和实时更新的应用中尤为突出, 因为缺少集成的多源检索能力可能导致信息不完整或过时。为了充分利用每种数据模态的优势并满足动态异构数据环境的需求, RAG 系统必须演进以支持协同的多源检索与综合。

2.2 RAG 中的智能体

RAG 已成为知识密集型任务的关键范式, 通过将检索机制与生成模型相结合, 显著增强了语言模型的能力。然而, 传统 RAG 实现通常依赖静态流水线, 难以处理多模态查询 [8,48]。近期基于智能体的 RAG 架构通过提升系统模块化和操作灵活性, 解决了这些局限 [11,21,29]。面向智能体的方法将查询处理分解为语义解析、跨模态检索和上下文感知生成等专门组件, 在保持整体适应性的同时实现针对性优化。PaperQA [32] 通过利用学术文献生成基于证据的响应, 减少了科学应用中的幻觉, 体现了这一思路。

基于此, Active RAG 方法 (如 FLARE[30]) 通过预期性检索引入了时间动态性, 从而提升了长文本生成中的性能。尽管取得了这些进展, 多模态集成方面的挑战依然存在。新兴的 Dynamic RAG 方法 [49,50] 提出了实体感知增强策略, 以动态整合检索到的实体表示, 在保持语义连贯性的同时解决上下文窗口限制。我们的 HM-RAG 框架通过一种利用大语言模型语义理解能力的层次化多智能体架构, 综合了这些创新。该设计支持动态查询自适应与多模态检索, 为跨多种数据模态的复杂信息检索与生成任务提供了优化方案。通过融合这些进展, HM-RAG 解决了多模态推理与知识综合中的关键挑战, 为构建更鲁棒、更自适应的 RAG 系统铺平了道路。

3 方法

我们提出 HM-RAG, 这是一个新颖的框架, 用于应对 RAG 系统中的复杂挑战。如图 2 所示, HM-RAG 采用创新的多智能体、多模态架构, 包含专门用于信息抽取和多源检索的智能体。给定一个自然语言问题 q 和一份参考文档 D , RAG 从 D 中检索语义相关的内容, 并将其与生成式语言模型相结合, 从而生成严格基于 D 的答案。该方法推动了多模态问答与多智能体 RAG 能力的发展。后续章节将详细阐述 HM-RAG 的架构设计。通过这一系统性描述, 我们阐明了该框架有效整合与利用多模态信息及多源检索的核心机制, 最终提升了 RAG 应用的准确性。

3.1 多模态知识预处理

本节重点讨论多模态数据处理, 旨在将文本数据和视觉图像转换为向量与图数据库表示, 以增强检索性能。本方法利用 VLMs 将视觉信息转码为文本表示, 再将其与原始文本语料库融合, 共同构建向量与图数据库。

3.1.1 多模态文本知识生成。传统的以实体为中心的多模态知识抽取方法依赖于预定义的类别边界, 限制了其识别新颖视觉概念的能力。我们利用 BLIP-2 框架 [34] 来发挥预训练 VLM 的开放词汇潜力。基于广义的视觉到语言转换范式:

$$T_v = \mathcal{D}_{blip2}(f_{align}(\mathcal{E}_{blip2}(I_v))) \quad (1)$$

其中, 视觉编码器 $\mathcal{E}_{blip2}$ 从输入图像 I_v 中提取特征, 跨模态对齐模块 f_{align} 则桥接视觉-语言语义。我们的框架通过利用原始文本数据的上下文精炼机制, 解决了过于简化的机器生成描述的关键局限性, 尤其是应对 BLIP-2 因缺乏视觉特异性而产生的过度压缩输出。

该过程分为三个协同阶段。首先, 通过已有架构 [10, 22, 39] 进行分层视觉编码, 生成图像块嵌入 $V_i \in \mathcal{R}^{d_v \times N_p}$ 。其次, 跨模态交互阶段中, 可学习查询 $Q_i \in \mathcal{R}^{d_q \times L_q}$ 通过缩放点积注意力机制关注视觉特征, 动态加权空间语义相关性。最后, 上下文感知文本生成阶段融合来自先前描述 $T_v^{i,t}$ 的潜在文本特征与跨模态表示, 进行自回归解码。该阶段的上下文精炼增强了语义对齐, 显著降低了最终输出 T_v 的描述模糊性和词汇稀疏性。

最终的多模态文本知识库是通过系统整合原始文本输入与生成的文本化表示而形成的。

$$T_m = \text{Concate}(T, T_v) \quad (2)$$

其中 T 对应于源文本语料库, 而 T_m 表示通过异构融合过程形成的多模态文本聚合。

3.1.2 多模态知识图谱构建。我们通过将 VLM 增强的描述与基于 LLM 的结构推理相协同, 构建多模态知识图谱 (MMKGs)。基于 VLM 生成的精细化视觉描述 T_v , 并可选地融合外部文本知识 T , 我们采用 LightRAG 框架 [18] 进行高效的多跳推理和动态知识集成:

$$G = \text{LightRAG}(T_0, T) \quad (3)$$

LightRAG 通过一种混合提取策略处理多模态输入。**实体-关系抽取:** 专用函数 f 将输入分解为实体 $E = \{e_1, \dots, e_n\}$ 和关系三元组 $R = \{(h_i, r_i, t_i)\}$, 其中 $h, t \in E$ 分别表示头/尾实体, $r \in R$ 表示关系。**双级推理增强:** 双尺度检索机制 $\text{Retrieve}_{\text{global}+\text{local}}$ 在推理过程中动态获取相关三元组; 全局检索识别主题聚类, 而局部抽取聚焦于实体特定的连接。

所构建的多模态知识图谱 $G = (E, R)$ 将知识形式化为三元组 (h, r, t) , 其中实体涵盖来自 T_0 的




图 2: HM-RAG 框架概述。该多智能体多模态框架分三个阶段运行：首先，分解智能体利用 LLM 对问题进行重写和分解，生成若干子查询。其次，多源检索智能体根据需从基于向量、图和网络的来源中检索 top-k 相关文档。最后，决策智能体通过投票机制和精炼过程生成最终答案。

视觉概念和来自 T 的文本知识。关键在于，视觉数据存储位置在图的构建过程中被嵌入，从而实现跨模态对齐。该架构建立了一个双向知识增强框架：语言模型通过图中嵌入的视觉-语义关系进行视觉上下文文化推理，视觉-语言模型则通过连续多模态集成动态更新知识嵌入，利用表示一致性约束有效降低幻觉概率。

3.2 多意图查询的分解代理

分解代理是所提框架的关键组成部分，旨在将复杂的多意图用户查询分解为连贯且可执行的子任务。该代理解决了传统系统的一个关键局限性，即难以处理需要在多个数据源之间进行联合推理的复合查询。通过利用层级解析机制，分解代理识别用户查询的潜在结构，并将其分解为原子单元，每个单元针对特定的数据模态或检索任务。

所提出的框架包含两个阶段，均由任务特定的 LLM 提示策略驱动。**分解必要性判断**：Agent 首先通过二元决策提示确定输入问题 Q 是否包含多个意图，该提示指导 LLM 将其分类为单意图或多意图。若输出为多意图，则 Q 进入分解阶段；否则直接返回原问题 Q 。**意图分解**：LLM 采用结构化提示将 Q 分解为候选子问题 $q = \{q_1, \dots, q_n\}$

，该提示受文献 [35] 启发：“根据原问题的意图，将其推理步骤分解为 2 到 3 个逻辑简单且相互关联的子问题，同时保留原问题中的关键词。”

3.3 多源即插即用检索智能体

我们提出了一种模块化多智能体检索框架，通过标准化接口动态组合异构多模态搜索策略。该系统将检索功能解耦为三个专用智能体——基于向量的检索智能体、基于图的检索智能体和基于网络的检索智能体——从而在确保跨多种搜索场景互操作性的同时实现领域无关的适应性。每个智能体遵循统一的通信协议，使向量语义搜索、图拓扑探索和实时网络检索能力能够无缝集成。该设计允许每个检索智能体作为即插即用组件运行，确保它们可被轻松集成或替换，而不影响整体系统性能。这种模块化不仅增强了灵活性，还保留了任务特定的优化目标，使框架对各种应用和数据模态具有高度适应性。

3.3.1 基于向量的细粒度信息检索智能体。该智能体采用一种朴素的检索架构[18]，以高效地搜索非结构化文本语料。给定用户查询 q ，系统首先利用编码器 ϵ_{text} 计

算其语义
嵌入 h_q :

$$h_q = \mathcal{E}_{text}(q) \quad (4)$$

其中 $h_q \in \mathbb{R}^d$ 表示查询在 d 维向量空间中的嵌入表示。

接下来, 系统使用余弦相似度计算查询嵌入 h_q 与所有文档嵌入 h_j 之间的语义相似度:

$$s_j = \frac{h_q^T h_j}{\|h_q\| \|h_j\|}, \quad \forall j \in [1, M] \quad (5)$$

其中 $j \in [1, M]$, M 为文档总数。相似度得分 s_j 量化了每个文档与查询的匹配程度, 作为检索文档排序的基础。

基于相似度得分, 系统检索出最相关的前 k 个文档:

$$\mathcal{R}_k = \{c_1, \dots, c_k\} \text{ s.t. } s_1 \geq s_2 \geq \dots \geq s_k \quad (6)$$

其中 $\mathcal{R}_k$ 表示 top- k 检索到的上下文集合, 确保只有最相关的信息用于后续处理。

随后, 语言模型基于检索到的上下文, 通过约束解码生成答案 A_v :

$$\mathcal{A}_v = \mathcal{P}(q, \mathcal{R}_k) = \text{Concate}(q, \text{Context}, \{c_1, \dots, c_k\}) \quad (7)$$

其中 $\mathcal{P}$ 表示生成过程, 该过程将查询 q 、检索得到的上下文 $\{c_1, \dots, c_k\}$ 以及额外的上下文信息拼接起来, 以生成最终答案。

具体地, 在给定查询 q 和检索上下文 $\mathcal{R}_k$ 的条件下, 生成词元序列 y 的条件概率被建模为:

$$p(y|q, \mathcal{R}_k) = \prod_{t=1}^T p_{lm}(y_t | y_{<t}, q, \mathcal{R}_k) \quad (8)$$

其中 p_{lm} 表示语言模型自回归生成过程中一个词元的条件概率, 确保生成的答案在上下文上保持连贯。

此外, 注意力机制将检索到的内容显式地融入生成过程:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q[h_q; H_{\mathcal{R}}]^T}{\sqrt{d_k}}\right)[h_q; H_{\mathcal{R}}] \quad (9)$$

其中 $H_{\mathcal{R}} \in \mathbb{R}^{K \times d}$ 堆叠检索分块的嵌入向量, $[h_q; H_{\mathcal{R}}]$ 将查询嵌入与检索分块嵌入拼接, 增强模型聚焦相关信息的能力。为确保生成答案的可靠性, 约束条件强制设定 $\text{top-}p = 1.0$ 且温度为 0, 从而基于最高概率词元进行确定性解码。这最大程度降低了幻觉风险, 保证了事实准确性。

3.3.2 基于图的检索代理用于关系信息。该代理利用 LightRAG 的图遍历能力来解析 MMKG [18] 上的多跳语义查询。给定输入查询 q , 代理通过 LightRAG 的联合注意力机制动态检索实体和关系, 构建上下文感知的子图 $G_q \subseteq G$ 。子图定

$$G_q = \{(h, r, t) | \text{LightRAG}_{graph}(q, h, r, t) > \tau\} \quad (10)$$

义为: 其中 LightRAG_{graph} 通过跨模态注意力将查询嵌入与图三元组表示对齐来计算相关性分数, 确保只有高度相关的三元组被包含在子图中。

为了高效处理复杂查询, 该智能体采用了一种兼顾效率与全面性的分层搜索策略。首先, 智能体利用关系特定的注意力权重, 优先检索与查询相关实体的局部 1 跳邻居。这确保了首先检索直接相连的实体和关系, 为后续探索奠定基础。其次, 智能体通过迭代消息传递识别跨模态路径, 将搜索范围扩展至全局。这使得智能体能够探索直接邻居之外的更深层语义关系, 从而增强检索信息的丰富性。

此外, 该框架是一个双层次检索框架, 通过三阶段检索过程将图结构知识与向量表示相结合。首先, 框架对输入查询 q 进行语义分解, 得到局部关键词 q_l 和全局关键词 q_g 。该步骤同时捕获细粒度与高层级语义信息。其次, 框架执行混合图-向量匹配。优化后的向量数据库将 q_l 与实体属性对齐, 同时将 q_g 映射至知识图谱 $G = (\mathcal{V}, \mathcal{E})$ 中的关系模式。这种混合方法确保了显式实体属性与隐式关系语义均被纳入考量。

最后, 为提升检索完整性, 该框架执行高阶上下文扩展。检索到的子图被扩展, 纳入检索节点和边的一跳邻居:

$$\mathcal{A}_g = \{v_i \in \mathcal{V} \wedge (v_i \in N_v \vee v_i \in N_e)\} \quad (11)$$

其中 N_v 和 N_e 分别表示被检索节点和边的一跳邻居。此步骤确保检索到的子图在捕获更广泛的上下文关系的同时, 保持结构完整性。最终答案 $\mathcal{A}_g$ 通过轻量级 LLM 以 $\mathcal{A}_g = \text{LLM}(\mathcal{A}_g)$ 生成。

3.3.3 面向实时信息的网络检索代理。网络检索组件在信息检索与自然语言生成之间扮演着关键桥梁角色, 显著提升了生成文本的语义保真度和事实支撑性。本研究使用 Google Serper API。系统通过参数化 API 请求向 Google 搜索引擎获取知识。对于输入查询 q , 检索过程形式化表示为:

$$\mathcal{R} = \text{Google}(q; \theta_{search}) \quad (12)$$

其中 θ_{search} 指定搜索配置参数。我们采用 $\theta_{search} = \{\text{num}_{results} = k, \text{language} = \text{en}, \text{type} = \text{web}\}$ 的设置。API 返回结构化结果 $\mathcal{A}_w = \{a_i\}_{i=1}^k$, 每个结果包含标题、摘要、URL 和位置排名元数据。

Google Serper 框架通过三种主要操作模式在实际部署场景中展现出特殊效能, 每种模式都满足了现代知识感知系统的关键需求。其一, 实时事实验证模块通过神经记忆查询计算事实正确性分数; 其二, 归因感知生成协议通

过双阶段注意力路由确保可追溯性；其三，自适应查询扩展机制通过差异化词项加权解决词汇不匹配问题。

3.4 多答案精炼的决策代理

一致性投票。该框架利用 ROUGE-L 和 BLEU 指标，评估基于向量、基于图和基于网络的检索系统生成的答案 $\{A_v, A_g, A_w\}$ 之间的语义一致性。首先为每个答案生成摘要 $\{S_v, S_g, S_w\}$ 。ROUGE-L 通过最长公共子序列 (LCS) 度量关键信息重叠程度，其定义为：

$$R_L = \frac{LCS(S_i, S_j)}{\max(|S_i|, |S_j|)} \quad (13)$$

其中分子代表摘要间最长公共子序列 (LCS) 的长度，分母则对分数进行归一化。该指标强调保留关键事实信息时的一致性。

BLEU 评估摘要之间 n 元组匹配的局部精确率，定义如下：

$$BLEU = \exp\left(\sum_{n=1}^k w_n \log p_n\right) \cdot \min\left(1, \frac{|S_j|}{|S_i|}\right) \quad (14)$$

其中 p_n 表示 n -gram 精确率， w_n 表示权重系数。该指标擅长检测术语或数值的精确匹配。

随后对 R_L 与 BLEU 进行加权融合，以平衡宏观语义对齐与微观细节一致性，从而衡量任意两个答案之间的相似度。若成对相似度超过预设阈值，则利用轻量级语言模型 (LLM) 精炼结果，生成最终答案 A ；若相似度低于阈值，则进入专家模型细化阶段。

专家模型精炼。对于存在冲突的答案，该框架利用大型语言模型 (LLM)、多模态大语言模型 (MLLM) 或基于思维链的语言模型 (Cot-LM)，通过融合多源证据来综合生成精炼回答。LLM 或 MLLM 处理原始查询 q 和检索到的证据，并生成最终答案 A 。该步骤起专家引导作用，确保即使初始答案存在差异，最终回答在上下文连贯性与事实准确性方面均能得到保障。

4 实验

4.1 实验设置

数据集。我们在两个多模态推理基准上进行了实验，这两个基准涵盖不同的模态配置，包括复杂问答 (ScienceQA) 和危机事件分类 (CrisisMMD)。

ScienceQA [40]。该数据集是首个大规模多模态科学问答基准，涵盖三大核心学科 (自然科学、社会科学和形式科学)。数据集包含 21,208 个精心策划的样本，按层次结构分布在 26 个主题、127 个类别和 379 种不同的推理技能上。每个实例将文本问题与可选的视觉背景 (图表、图形或照片) 相结合，训练集、验证集和测试集分别为 12,726、4,214 和 4,268 个样本，划分均衡。

遵循 LLaVA [36] 建立的评估协议，我们报告所有测试样本的平均准确率，以评估模型在多模态理解和多步科学推理中的表现。值得注意的是，34.6% 的测试问题需要同时处理视觉和文本信息才能得出正确答案。

CrisisMMD [2] 数据集为灾害响应应用提供了一个富有挑战性的多模态集合，包含约 35,000 条来自真实危机事件的社交媒体帖子，涵盖图像与文本内容。其标注方案全面，设有七种不同的灾害类别和四个粒度级别的严重程度。该数据集的独特价值在于捕获真实的用户生成内容，保留了危机通信中固有的自然噪声模式和复杂的跨模态关系。这些特性使其特别适用于评估零样本适应模型，因为在此基准上的成功表现直接反映了在动态应急场景 (通常缺乏干净数据和显式模态对齐) 中的实际部署能力。

实现细节 我们采用 DeepSeek-R1-70B 进行动态图构建，并通过 Qwen2.5-7B 的参数自适应框架优化 LightRAG 的混合检索机制，这与 VaLik [37] 一致。在决策优化阶段，使用 GPT-4o 处理 ScienceQA 数据集，使用 GPT-4 分析 CrisisMMD 数据集。所有多模态推理工作流在单块 NVIDIA A800-80GB GPU 上运行，通过内存优化的并行化技术无缝支持图神经网络计算与检索增强生成任务的并发执行。

4.2 主要结果

在本节中，我们在多个基准上对 HM-RAG 与当前最优的零样本 LLM、VLM 及 RAG 增强方法进行了系统评估。结果如表 1 和表 2 所示，表明 HM-RAG 在所有对比方法中均具有一致的优越性。

4.2.1 ScienceQA 上的结果。表 1 系统量化了 HM-RAG 与现有零样本方法在 ScienceQA 数据集上的多模态问答性能。如表所示，HM-RAG 取得了 93.73% 的最新平均准确率，分别超越此前最优零样本 VLM 方法 LLaMA-SciTune 和 GPT-4o 达 4.11% 和 2.82%，并显著优于单智能体 RAG 变体。与基于向量、基于图和基于网页的基线方法相比，HM-RAG 分别实现了 12.95%、12.71% 和 12.13% 的绝对提升。在社会科学 (SOC) 任务的准确率上观察到显著增益，相较于基于网页和基于图的基线方法，提升幅度分别达到 24.38% 和 20.65%。该框架还超过人类专家性能达 6.03%。

4.2.2 CrisisMMD 上的结果。表 2 全面评估了 CrisisMMD 基准上的多模态理解能力。我们的分析揭示了三个关键发现。首先，多模态增强的大语言模型在所有任务上均持续优于纯文本大语言模型和专用视觉语言模型。所提方法实现了最先进的性能，平均准确率达 58.55

表 1: ScienceQA 数据集上 Top-1 检索性能比较 (准确率 %)。#P 表示可训练参数数量。类别包括: NAT (自然科学)、SOC (社会科学)、LAN (语言科学)、TXT (文本上下文)、IMG (图像上下文)、NO (无上下文)、G1-6 (1-6 年级) 和 G7-12 (7-12 年级)。所呈现的比较基于从 ScienceQA 排行榜获得的当前最先进的零样本学习结果¹。

Learning	Models	#P	Subject			Context Modality			Grade		Average
			NAT	SOC	LAN	TXT	IMG	NO	G1-6	G7-12	
Baseline	Human	-	90.23	84.97	87.48	89.60	87.50	88.10	91.59	82.42	88.40
Zero-shot LLMs	ChatGPT [56]	-	-	-	-	-	-	-	-	-	69.41
	GPT-3 (0-shot) [40]	173B	75.04	66.59	78.00	74.24	65.74	79.58	76.36	69.87	74.04
	DDCoT (GPT-3) [58]	175B	78.60	73.90	80.45	77.27	69.96	82.93	80.65	73.50	78.09
	CoT GPT-3 + Doc [24]	173B	-	-	-	-	-	-	-	-	79.91
	DDCoT (ChatGPT) [58]	175B	80.15	76.72	82.82	78.89	72.53	85.02	82.86	75.21	80.15
Zero-shot VLMs	LaVIN-13B [56]	-	-	-	-	-	-	-	-	-	77.54
	LLaMA-SciTune [23]	7B	84.50	94.15	82.91	88.35	83.64	88.74	85.05	85.60	86.11
	LG-VQA (BLIP-2) [17]	-	-	-	-	-	-	-	-	-	86.32
	LG-VQA (CLIP) [17]	-	-	-	-	-	-	-	-	-	87.22
	LLaMA-SciTune [23]	13B	89.30	95.61	87.00	93.08	86.67	91.75	84.37	91.30	90.03
Zero-shot Single-agent RAG	Vector-based [37]	7B	84.54	74.24	86.91	82.74	72.53	90.03	84.51	80.28	82.98
	Graph-based [37]	7B	84.15	75.14	87.64	82.99	73.18	89.69	84.40	80.95	83.16
	Web-based	7B	83.79	72.89	91.82	81.09	70.55	94.01	85.98	79.30	83.59
	GPT-4o [26]	-	92.72	93.48	86.09	92.67	90.88	87.60	92.91	88.00	91.16
Zero-shot Multi-agent RAG	HM-RAG	-	94.36	90.66	94.91	93.79	89.94	96.03	94.42	92.49	93.73

表 2: CrisisMMD 数据集上 Top-1 检索性能对比 (准确率 %)。后缀-I 表示指令微调变体。加粗表示最优值。Task 1 为二分类任务, Task 2 和 Task 2 Merged 为多分类任务。对比结果来自文献[37], 该工作是在 CrisisMMD 数据集上基于 LLM 的开创性研究。

Method	#P	Task 1	Task 2	Task 2 Merged	Average
Single-modal LLMs					
LLaMA-2 [51]	7B	62.32	18.32	21.45	34.03
	13B	63.80	21.82	33.15	39.59
	70B	63.15	28.87	36.89	42.97
Qwen2.5 [55]	7B	65.04	44.52	45.33	51.63
	32B	67.28	46.94	47.07	53.76
	72B	67.95	50.51	50.29	56.25
GPT-4 [1]	-	66.83	47.25	49.44	54.51
Multimodal VLMs					
Qwen2-VL [52]	2B-I	47.56	7.60	7.42	20.86
	7B-I	62.45	32.68	34.20	43.11
	72B-I	65.80	47.21	48.28	53.76
LLaVA [36]	7B	54.00	28.01	30.61	37.54
	13B	60.58	20.14	23.44	34.72
	34B	56.44	25.15	25.07	35.55
CLIP [45]	-	43.36	17.88	20.79	27.34
GPT-4o [26]	-	68.20	47.58	49.55	55.11
Single-agent RAG					
Vector-based [37]	7B	67.49	45.11	45.94	52.85
Graph-based [37]	7B	68.90	50.02	50.69	56.54
Multi-agent RAG					
HM-RAG	-	72.06	51.50	52.09	58.55

%, 相较于最强基线 (GPT-4o) 和纯文本变体 (Qwen2.5-72B) 分别取得了 2.44% 和 3.44% 的绝对提升, 尽管仅使用了 7B 参数。

其次, 模型规模与性能提升之间呈现非线性关系。尽管 Qwen2.5-72B (纯文本) 取得了 56.25% 的平均准确率, 但我们 7B 多模态增强变体实现了 2.3% 的绝对提升, 展现出更高的参数效率。这一趋势在跨模态场景中同样成立, Qwen2-VL-72B-I (VLM) 在参数数量相同的情况下, 性能仍比我们的方法低 4.79%。

第三, 多模态集成显著影响任务性能。与纯文本和纯图变体相比, 我们的方法在平均准确率上分别提升了 5.7% 和 2.01%, 凸显了多源推理的有效性。值得注意的是, 在任务 1 上 72.06% 的准确率创造了新的基准, 比 GPT-4o 高出 3.86%, 展现了强大的视觉-文本对齐能力。

4.3 定性分析

我们提供了一个如图 3 所示的预测示例, 以证明我们所提出模型的有效性。该示例经过精心挑选, 以展示模型处理复杂模式并做出准确选择的能力。对更多案例感兴趣的读者, 附录 A 中提供了更详细的示例集。在给定的示例中, 多源检索代理均产生了错误的结果, 因为数据库中未记录该问题的相关信息。为应对这种情况, 决策代理中的专家精化机制被用于进行高层级思考, 从而推导出正确结果。这体现了

¹<https://scienceqa.github.io/leaderboard.html>




图 3: 案例研究: HM-RAG 与基线方法 (基于向量的检索智能体、基于图的检索智能体和基于网络的检索智能体) 的比较。

表 3: HM-RAG 不同变体在 ScienceQA 数据集上的性能比较。组件包括: VA (向量检索代理)、GA (图检索代理)、WA (网络检索代理) 和 DA (决策代理)。

Agent Configuration				NAT	SOC	LAN	TXT	IMG	NO	G1-6	G7-12	Average
VA	GA	WA	DA									
×	✓	✓	✓	90.72	88.08	94.09	89.30	84.58	95.68	92.47	88.46	91.04
✓	×	✓	✓	91.21	87.96	94.73	90.32	85.62	95.61	92.22	90.05	91.44
✓	✓	×	✓	88.99	84.81	90.27	88.17	83.09	91.78	89.46	86.62	88.45
✓	✓	✓	×	83.79	72.89	91.82	81.09	70.55	94.01	85.98	79.30	83.59
✓	✓	✓	✓	94.36	90.66	94.91	93.79	89.94	96.03	94.42	92.49	93.73

我们的模型在知情决策方面的熟练性，相比依赖单一类型的检索机制，确保了更强的鲁棒性。

retrieval mechanism.

4.4 消融实验

表 3 通过在 ScienceQA 上进行受控消融研究，系统评估了各智能体组件的贡献。关于该框架的设计，主要得出三点关键见解。首先，决策智能体 (DA) 是最关键的要素，其移除会导致最显著的性能下降，降幅达 10.82%。该组件在多源决策整合中尤为重要，当 DA 被禁用时，基于图像的任务和社会推理任务的准确率分别显著下降 21.56% 和 19.60%。其次，基于网络的检索智能体 (WA) 展示了强大的集成能力。停用 WA 会导致平均性能下降 5.63%，对 7-12 年级任务的影响更为显著，准确率下降 6.35%。第三，完全集成的智能体系统在 93.73% 的准确率下达到峰值性能，比最佳消融配置高出 2.44 个百分点。这一最优配置在所有任务类别中均实现了持续提升，特别是在多模态场景中，与基线相比，基于文本的任务和基于图像的任务分别提升了 3.70% 和 4.80%。该框架在处理复杂查询方

面也表现出色，在 7-12 年级问题上准确率提高了 2.64%。这些实证结果证实了该架构在协调专业化智能体以实现整体多模态推理方面的有效性。

5 结论

本文提出了 HM-RAG，一种新颖的层级式多智能体多模态检索增强生成框架，旨在应对复杂多模态查询处理与知识合成中的挑战。HM-RAG 通过集成专用智能体实现查询分解、多源检索与决策优化，开创了协同智能的先河，能够在结构化、非结构化和基于图的数据之间进行动态知识合成。在 ScienceQA 和 CrisisMMD 基准上的大量实验表明，HM-RAG 在多模态问答与分类的准确性上达到了最先进水平，相较于所有类别的基线方法均实现了显著提升。本工作通过有效应对多模态推理与知识合成中的关键挑战，推动了 RAG 系统的发展，为在多样应用领域中构建更鲁棒、更灵活的信息检索与生成系统奠定了基础。

REFERENCES

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. GPT-4 Technical Report. *arXiv preprint arXiv:2303.08774* (2023).
- [2] Firoj Alam, Ferda Ofli, and Muhammad Imran. 2018. CrisisMMD: Multimodal Twitter Datasets from Natural Disasters. In *Proceedings of the International AAAI Conference on Web and Social Media*, Vol. 12.
- [3] Abhijit Anand, Vinay Setty, Avishek Anand, et al. 2023. Context Aware Query Rewriting for Text Rankers using LLM. *arXiv preprint arXiv:2308.16753* (2023).
- [4] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. 2023. Self-rag: Learning to retrieve, generate, and critique through self-reflection. *arXiv preprint arXiv:2310.11511* (2023).
- [5] Sukanya Bag, Ayushman Gupta, Rajat Kaushik, and Chirag Jain. 2024. RAG Beyond Text: Enhancing Image Retrieval in RAG Systems. In *2024 International Conference on Electrical, Computer and Energy Technologies (ICEET)*. IEEE, 1–6.
- [6] Mirco Bonomo and Simone Bianco. 2025. Visual RAG: Expanding MLLM Visual Knowledge without Fine-tuning. *arXiv preprint arXiv:2501.10834* (2025).
- [7] Zhanpeng Chen, Chengjin Xu, Yiyang Qi, and Jian Guo. 2024. MLLM Is a Strong Reranker: Advancing Multimodal Retrieval-augmented Generation via Knowledge-enhanced Reranking and Noise-injected Training. *arXiv preprint arXiv:2407.21439* (2024).
- [8] Yuheng Cheng, Ceyao Zhang, Zhengwen Zhang, Xiangrui Meng, Sirui Hong, Wenhao Li, Zihao Wang, Zekai Wang, Feng Yin, Junhua Zhao, et al. 2024. Exploring Large Language Model based Intelligent Agents: Definitions, Methods, and Prospects. *arXiv preprint arXiv:2401.03428* (2024).
- [9] Yuxin Dong, Shuo Wang, Hongye Zheng, Jiajing Chen, Zhenhong Zhang, and Chihang Wang. 2024. Advanced RAG Models with Graph Structures: Optimizing Complex Knowledge Reasoning and Text Generation. In *2024 5th International Symposium on Computer Engineering and Intelligent Communications (ISCEIC)*. IEEE, 626–630.
- [10] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiuhua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. 2020. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *arXiv preprint arXiv:2010.11929* (2020).
- [11] Gustavo de Aquino e Aquino, Nádila da Silva de Azevedo, Leandro Youiti Silva Okimoto, Leonardo Yuto Suzuki Camelo, Hendrio Luis de Souza Bragança, Rubens Fernandes, Andre Printes, Fábio Cardoso, Raimundo Gomes, and Israel Gondres Torné. 2025. From RAG to Multi-Agent Systems: A Survey of Modern Approaches in LLM Development. (2025).
- [12] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, Dasha Metropolitan, Robert Osazuwa Ness, and Jonathan Larson. 2024. From Local to Global: A GraphRAG Approach to Query-Focused Summarization. *arXiv preprint arXiv:2404.16130* (2024).
- [13] Manuel Faysse, Hugues Sibille, Tony Wu, Bilel Omrani, Gautier Viaud, Céline Hudelot, and Pierre Colombo. 2024. ColPali: Efficient Document Retrieval with Vision Language Models. In *The Thirteenth International Conference on Learning Representations*.
- [14] Matthias Fey, Weihua Hu, Kexin Huang, Jan Eric Lenssen, Rishabh Ranjan, Joshua Robinson, Rex Ying, Jiaxuan You, and Jure Leskovec. 2023. Relational Deep Learning: Graph Representation Learning on Relational Databases. *arXiv preprint arXiv:2312.04615* (2023).
- [15] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Haofen Wang, and Haofen Wang. 2023. Retrieval-Augmented Generation for Large Language Models: A Survey. *arXiv preprint arXiv:2312.10997* 2 (2023).
- [16] Jeanie Genesis and Frazier Keane. 2025. Integrating Knowledge Retrieval with Generation: A Comprehensive Survey of RAG Models in NLP. (2025).
- [17] Deepanway Ghosal, Navonil Majumder, Roy Ka-Wei Lee, Rada Mihalcea, and Soujanya Poria. 2023. Language Guided Visual Question Answering: Elevate Your Multimodal Language Model Using Knowledge-Enriched Prompts. *arXiv preprint arXiv:2310.20159* (2023).
- [18] Zirui Guo, Lianghao Xia, Yanhua Yu, Tu Ao, and Chao Huang. 2024. LightRAG: Simple and Fast Retrieval-Augmented Generation. *arXiv preprint arXiv:2410.05779* (2024).
- [19] Shailja Gupta, Rajesh Ranjan, and Surya Narayan Singh. 2024. A Comprehensive Survey of Retrieval-Augmented Generation (RAG): Evolution, Current Landscape and Future Directions. *arXiv preprint arXiv:2410.12837* (2024).
- [20] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Mingwei Chang. 2020. Retrieval Augmented Language Model Pre-Training. In *International Conference on Machine Learning*. PMLR, 3929–3938.
- [21] Siwei Han, Peng Xia, Ruiyi Zhang, Tong Sun, Yun Li, Hongtu Zhu, and Huaxiu Yao. 2025. MDocAgent: A Multi-Modal Multi-Agent Framework for Document Understanding. *arXiv preprint arXiv:2503.13964* (2025).
- [22] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep Residual Learning for Image Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 770–778.
- [23] Sameera Horawalavithana, Sai Munikoti, Ian Stewart, and Henry Kvinge. 2023. SCITUNE: Aligning Large Language Models with Scientific Multimodal Instructions. *arXiv preprint arXiv:2307.01139* (2023).
- [24] Cheng-Yu Hsieh, Si-An Chen, Chun-Liang Li, Yasuhisa Fujii, Alexander Ratner, Chen-Yu Lee, Ranjay Krishna, and Tomas Pfister. 2023. Tool Documentation Enables Zero-Shot Tool-Usage with Large Language Models. *arXiv preprint arXiv:2308.00675* (2023).
- [25] Anwen Hu, Haiyang Xu, Jiabo Ye, Ming Yan, Liang Zhang, Bo Zhang, Chen Li, Ji Zhang, Qin Jin, Fei Huang, et al. 2024. mPLUG-DocOwl 1.5: Unified Structure Learning for OCR-free Document Understanding. *arXiv preprint arXiv:2403.12895* (2024).
- [26] Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. 2024. GPT-4o System Card. *arXiv preprint arXiv:2410.21276* (2024).
- [27] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. 2022. Few-shot Learning with Retrieval Augmented Language Models. *arXiv preprint arXiv:2208.03299* 1, 2 (2022), 4.
- [28] Cheonsu Jeong. 2024. A Graph-Agent-Based Approach to Enhancing Knowledge-Based QA with Advanced RAG. *Knowledge Management Research* 25, 3 (2024), 99–119.
- [29] Cheonsu Jeong. 2024. A Study on the Implementation Method of an Agent-Based Advanced RAG System Using Graph. *arXiv preprint arXiv:2407.19994* (2024).
- [30] Zhengbao Jiang, Frank F Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan, and Graham Neubig. 2023. Active Retrieval Augmented Generation. *arXiv preprint arXiv:2305.06983* (2023).
- [31] Omar Khattab and Matei Zaharia. 2020. ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 39–48.
- [32] Jakub Lála, Odhran O'Donoghue, Aleksandar Shtedritski, Sam Cox, Samuel G Rodrigues, and Andrew D White. 2023. PaperQA: Retrieval-Augmented Generative Agent for Scientific Research. *arXiv preprint arXiv:2312.07559* (2023).
- [33] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. 2020. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems* 33 (2020), 9459–9474.
- [34] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. 2023. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. In *International Conference on Machine Learning*. PMLR, 19730–19742.
- [35] Weijie Li, Jin Wang, Liang-Chih Yu, and Xuejie Zhang. 2025. Topology-of-Question-Decomposition: Enhancing Large Language Models with Information Retrieval for Knowledge-Intensive Tasks. In *Proceedings of the 31st International Conference on Computational Linguistics*. 2814–2833.
- [36] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. 2023. Visual Instruction Tuning. *Advances in Neural Information Processing Systems* 36 (2023), 34892–34916.
- [37] Junming Liu, Siyuan Meng, Yanting Gao, Song Mao, Pinlong Cai, Guohang Yan, Yirong Chen, Zilin Bian, Botian Shi, and Ding Wang. 2025. Aligning Vision to Language: Text-Free Multimodal Knowledge Graph Construction for Enhanced LLMs Reasoning. *arXiv preprint arXiv:2503.12972* (2025).
- [38] Jiawang Liu, Ye Tao, Fei Wang, Hui Li, and Xiugong Qin. 2025. SiQA: A Large Multi-Modal Question Answering Model for Structured Images Based on RAG. In *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 1–5.
- [39] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. 2021. Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 10012–10022.
- [40] Pan Lu, Swaroop Mishra, Tanglin Xia, Liang Qiu, Kai-Wei Chang, Song-Chun Zhu, Oyvind Tafjord, Peter Clark, and Ashwin Kalyan. 2022. Learn to Explain: Multimodal Reasoning via Thought Chains for Science Question Answering. *Advances in Neural Information Processing Systems* 35 (2022), 2507–2521.
- [41] Chuwei Luo, Yufan Shen, Zhaoqing Zhu, Qi Zheng, Zhi Yu, and Cong Yao. 2024. LayoutLLM: Layout Instruction Tuning with Large Language Models for Document Understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 15630–15640.
- [42] Costas Mavromatis and George Karypis. 2024. GNN-RAG: Graph Neural Retrieval for Large Language Model Reasoning. *arXiv preprint arXiv:2405.20139* (2024).
- [43] Humza Naveed, Asad Ullah Khan, Shi Qiu, Muhammad Saqib, Saeed Anwar, Muhammad Usman, Naveed Akhtar, Nick Barnes, and Ajmal Mian. 2023. A Comprehensive Overview of Large Language Models. *arXiv preprint arXiv:2307.06435* (2023).
- [44] Tyler Thomas Procko and Omar Ochoa. 2024. Graph Retrieval-Augmented Generation for Large Language Models: A Survey. In *2024 Conference on AI, Science, Engineering, and Technology (AIxSET)*. IEEE, 166–169.

- [45] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. 2021. Learning Transferable Visual Models From Natural Language Supervision. In *International Conference on Machine Learning*. PmlR, 8748–8763.
- [46] Monica Riedler and Stefan Langer. 2024. Beyond Text: Optimizing RAG with Multimodal Inputs for Industrial Applications. *arXiv preprint arXiv:2410.21943* (2024).
- [47] Tolga Şakar and Hakan Emekci. 2025. Maximizing RAG efficiency: A comparative analysis of RAG methods. *Natural Language Processing* 31, 1 (2025), 1–25.
- [48] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. 2023. Toolformer: Language models can teach themselves to use tools. *Advances in Neural Information Processing Systems* 36 (2023), 68539–68551.
- [49] Weihang Su, Yichen Tang, Qingyao Ai, Zhijing Wu, and Yiqun Liu. 2024. DRAGIN: Dynamic Retrieval Augmented Generation based on the Real-time Information Needs of Large Language Models. *arXiv preprint arXiv:2403.10081* (2024).
- [50] Sabrina Toro, Anna V Anagnostopoulos, Susan M Bello, Kai Blumberg, Rhiannon Cameron, Leigh Carmody, Alexander D Diehl, Damion M Dooley, William D Duncan, Petra Fey, et al. 2024. Dynamic Retrieval Augmented Generation of Ontologies using Artificial Intelligence (DRAGON-AI). *Journal of Biomedical Semantics* 15, 1 (2024), 19.
- [51] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. 2023. Llama 2: Open Foundation and Fine-Tuned Chat Models. *arXiv preprint arXiv:2307.09288* (2023).
- [52] Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, et al. 2024. Qwen2-VL: Enhancing Vision-Language Model’s Perception of the World at Any Resolution. *arXiv preprint arXiv:2409.12191* (2024).
- [53] Junde Wu, Jiayuan Zhu, Yunli Qi, Jingkun Chen, Min Xu, Filippo Menolascina, and Vicente Grau. 2024. Medical Graph RAG: Towards Safe Medical Large Language Model via Graph Retrieval-Augmented Generation. *arXiv preprint arXiv:2408.04187* (2024).
- [54] Peng Xia, Kangyu Zhu, Haoran Li, Tianze Wang, Weijia Shi, Sheng Wang, Linjun Zhang, James Zou, and Huaxiu Yao. 2024. MMed-RAG: Versatile Multimodal RAG System for Medical Vision Language Models. *arXiv preprint arXiv:2410.13085* (2024).
- [55] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. 2024. Qwen2.5 Technical Report. *arXiv preprint arXiv:2412.15115* (2024).
- [56] Xiaocui Yang, Wenfang Wu, Shi Feng, Ming Wang, Daling Wang, Yang Li, Qi Sun, Yifei Zhang, Xiaoming Fu, and Soujanya Poria. 2023. MM-BigBench: Evaluating Multimodal Models on Multimodal Content Comprehension Tasks. *arXiv preprint arXiv:2310.09036* (2023).
- [57] Tianjun Zhang, Shishir G Patil, Naman Jain, Sheng Shen, Matei Zaharia, Ion Stoica, and Joseph E Gonzalez. 2024. RAFT: Adapting Language Model to Domain Specific RAG. In *First Conference on Language Modeling*.
- [58] Ge Zheng, Bin Yang, Jiajin Tang, Hong-Yu Zhou, and Sibe Yang. 2023. DD-CoT: Duty-Distinct Chain-of-Thought Prompting for Multimodal Reasoning in Language Models. *Advances in Neural Information Processing Systems* 36 (2023), 5168–5191.
- [59] Zhiqiang Zhong and Davide Mottin. 2023. Knowledge-augmented Graph Machine Learning for Drug Discovery: From Precision to Interpretability. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 5841–5842.

A 预测示例

我们在图 3 中展示了额外的预测示例。此外，我们包含了两个代表性问题， 分别有或没有图像

用于评估模型语言推理能力的上下文。HM-RAG 始终生成准确的答案。

Question: Which object has the least thermal energy?

Choices: (A) a 250-gram glass of water at a temperature of 29°C
(B) a 250-gram glass of water at a temperature of 14°C ✓
(C) a 250-gram glass of water at a temperature of 16°C

object depends on both
The one with the lowest temperature will have the least thermal energy. In this case, a 250-gram glass of water at a temperature of 14°C has the lowest temperature among the options provided.
References: [DC] The objects are identical except for their temperatures (File: chunk 65).

Answer: The answer is (B).

Graph-based

Thermal energy is the energy that is associated with the motion of atoms and molecules. The faster the atoms and molecules move, the more thermal energy the object has.
The temperature of an object is a measure of the average kinetic energy of the atoms and molecules in the object. So, the object with the lowest temperature has the least thermal energy.

Answer: The answer is (B).

Web-based

Which object has more thermal energy? The objects are identical except for their temperatures. a 100-gram glass of apple juice at ...
https://www.gauthmath.com/solution/1805304034624517/Which-object-has-more-thermal-energy-The-objects-are-identical-except-for-their-

Answer: The answer is (B).

HMAgent

Temperature measures how hot or cold matter is. If the particles in matter slow down, the temperature goes down. The matter now has both less thermal energy and a lower temperature. All three glasses of water have the same mass but different temperatures. Since the 14°C glass of water is the coldest, it has the least thermal energy.

Answer: The answer is (B).

Text-based

The text is actually using a different rhetorical device: an open secret, where something is widely known among some people but denied by the subject. However, this is not one of the provided options and does not fit into the given choices for figure of speech.
References: [DC] Context: N/A (No specific document chunk references are directly applicable to this context.).

Answer: The answer is (B). ✗

Graph-based

In the context provided, ...An open secret refers to something that is widely known but not publicly acknowledged or officially admitted.
While (A) oxymoron combines contradictory terms (like "jumbo shrimp"), and (B) hyperbole involves exaggeration, neither accurately describes the phrase in context.
References: [KG] Genetics studies phenotypes as traits resulting from genotypes, such as Zuri's spotted coat. (File: 2025-03-05 19:18:00).

Web-based

For the time being, certainly, it had been found necessary to make a readjustment of rations (Squealer always spoke ...
https://quizlet.com/674788055/eleveth-grade-c5-classify-the-figure-of-speech-euphemism-hyperbole-oxymoron-paradox-flash-cards/.

Answer: The answer is (A).

HMAgent

The text uses an oxymoron, a joining of two seemingly contradictory terms. Open secret is a contradiction, because open describes something that is freely or publicly known, and a secret is hidden.

Answer: The answer is (A).

图 4：单模态问答对比



Question: Which better describes the Daintree rain forest ecosystem?

Choices: (A) It has year-round rain. It also has soil that is poor in nutrients. ✓

(B) It has cold winters. It also has many different types of organisms.

Text-based

According to the provided information and context from the Document Chunks, the Daintree rain forest ecosystem in northeastern Australia better fits the description "It has year-round rain. It also has soil that is poor in nutrients." This aligns with typical characteristics of a tropical rainforest, as opposed to an option describing cold winters and limited biodiversity.

Answer: The answer is (A).

Graph-based

Based on the provided context, I will now generate a comprehensive summary about ... [KG] Genes are fundamental units of heredity that carry biological instructions for traits and characteristics, passed from parents to offspring through generations.

Answer: The answer is (A).

Web-based


Daintree Rainforest Wikipedia The Daintree Rainforest, also known as the Daintree, is a region on the northeastern coast of Queensland, Australia, about 105 km (65 mi), by road, north of ...uff1a https://en.wikipedia.org/wiki/Daintree_Rainforest.

Answer: The answer is (A).

HMAgent

It has year-round rain. It also has soil that is poor in nutrients.

Answer: The answer is (A).



Question: Which of the following organisms is the primary consumer in this food web?

Choices: (A) copepod ✓
(B) black crappie
(C) bacteria

Text-based

In a food web, primary consumers are organisms that eat producers (such as plants) or other primary consumers. From the given information and the context of Little Rock Lake, the black crappie (option B) is listed as a consumer in the ecosystem model. This indicates it feeds on smaller organisms within the lake, making it a primary consumer.

Answer: The answer is (B). ✗

Graph-based

Based on the provided food web, black crappie likely feed on smaller organisms like copepods or zooplankton, making it a primary consumer in this ecosystem.

Answer: The answer is (B). ✗

Web-based

Below is a food web from Little Rock Lake, a freshwater lake ecosystem in Wisconsin. black crappie bacteria shiner green algae water flea ... <https://www.gauthmath.com/solution/1794627532113926>.

Answer: The answer is (A).

HMAgent

Bacteria crappie has arrows pointing to it from the water flea, the rotifer and the shiner. None of these organisms is a producer, so the black crappie is not a primary consumer. The bacteria have arrows pointing to them from the waterpod and the shiner. Neither the waterpod nor the shiner is a produce, so the are not primary consumers.

The answer is (A).

图 5: 多模态问答对比。